PROJETO 2 | APRENDIZADO DE MÁQUINA | 23 DE OUTUBRO DE 2026

Ciências da Natureza no ENEM 2023

Preparação dos dados, relações entre perfis e modelos iniciais

Alvo: `NU_NOTA_CN`. **Natureza do documento:** relatório técnico de andamento. Autoria da equipe e endereço público do repositório ainda não foram informados.

Resumo. Este trabalho investiga associações entre condições socioeconômicas, características escolares, perfil demográfico e a nota de Ciências da Natureza no ENEM 2023. A fonte nacional foi preservada e validada. Dos 2.692.427 registros com nota observada, 2.153.941 compõem o desenvolvimento e 538.486 permanecem no teste reservado. Foram examinadas 40 entradas em relação à nota e todos os seus 780 pares. Renda familiar, computadores e escolaridade dos responsáveis apresentam diferenças descritivas relevantes entre grupos. Na comparação inicial, regressão linear e Ridge obtiveram RMSE de aproximadamente 76,48 pontos, contra 87,92 da referência pela média. O projeto inclui um frontend em Python para consultar resultados agregados. Os achados são observacionais e preliminares; a avaliação final do teste não foi realizada.

Palavras-chave: ENEM; Ciências da Natureza; regressão; análise exploratória; reprodutibilidade.

1 Problema, fonte e população analisada

O objetivo é avaliar em que medida o perfil disponível permite estimar a nota de CN e descrever como ela varia entre grupos. Os microdados e o dicionário provêm da edição de 2023 disponibilizada pelo Inep [1]. A pesquisa considera a base nacional; o recorte do Ceará, disponível na interface, não substitui essa população.

Etapa ou condição	Registros
Base nacional preparada / colunas preservadas	3.933.955 / 76
Alvo CN observado, incluindo zeros	2.692.427
Alvo CN ausente, mantido no diagnóstico	1.241.528
Desenvolvimento / teste reservado	2.153.941 / 538.486
Notas zero no desenvolvimento	13.236
Linhas removidas na preparação / IDs duplicados	0 / 0

Fonte: elaboração com os microdados do Inep (2023), somente desenvolvimento.

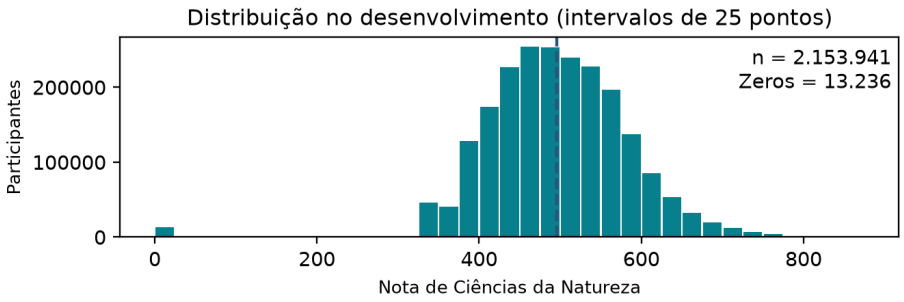


Figura 1: Distribuição da nota CN, com notas zero preservadas.

Fonte: elaboração com os microdados do Inep (2023), somente desenvolvimento.

Leitura: A média é 495,77, a mediana 493,9 e o desvio amostral 87,92 pontos. O alvo não foi imputado. Ausência de nota e nota zero são situações distintas.

2 Preparação, protocolo e medidas das relações

O CSV original foi lido em latin-1, com separador ponto e vírgula e lotes de até 50 mil linhas. A preparação gerou 79 partes Parquet com compressão, diagnóstico de qualidade e hashes SHA-256. Foram conferidos identificadores, duplicatas, tipos, conversões, contagens e integridade. Marcadores declarados de ausência foram normalizados; não houve descarte por idade, condição de treineiro ou nota zero.

O alvo observado definiu a elegibilidade. A divisão fixa usa 80% para desenvolvimento, 20% para teste e semente 42. No desenvolvimento, utiliza-se `KFold(3, shuffle=True, random_state=42)` com as mesmas dobras em todas as comparações. Os transformadores são ajustados apenas no treino de cada dobra, em *Pipelines* [5]: mediana e padronização para Q005; categoria explícita de ausência e codificação *one-hot* para as demais entradas.

Escopo da análise ampliada

As 40 entradas são Q005, 14 características demográficas/escolares e de localização, língua estrangeira e as 24 questões socioeconômicas restantes do questionário. Foram gerados 254 perfis de categorias e 29.709 células de cruzamento. "Todas as relações" significa aqui as 40 relações com CN e os $\binom{40}{2} = 780$ pares de entradas: 741 categórico–categórico e 39 mistos. Não se afirma que isso esgote interações de três ou mais variáveis ou modelos causais.

Estatísticas utilizadas

Para grupos g, contagens n_g, médias $\bar{y}_g$ e média global $\bar{y}$, mede-se a diferença entre grupos por

$$\eta^2 = \frac{\sum_g n_g(\bar{y}_g - \bar{y})^2}{\sum_i (y_i - \bar{y})^2}.$$

É uma decomposição descritiva da variação da nota; não é desempenho em dados de validação. Para duas categóricas, usa-se V de Cramér [2]:

$$E_{ij} = \frac{n_{i\cdot} n_{\cdot j}}{n}, \qquad \chi^2 = \sum_{ij} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}, \qquad V = \sqrt{\frac{\chi^2}{n \min(r-1, c-1)}}.$$

O cálculo não usa correção de continuidade. V varia de zero a um e não fornece direção. Nos pares com Q005, η^2 descreve a entrada numérica entre categorias da outra entrada. Não se comparam V e η^2 como se fossem a mesma medida.

Somente Q005 recebe correlações numéricas com CN: Pearson mede associação linear e Spearman mede associação monotônica pelos postos, com empates tratados [3, 4]. Seus resultados foram, respectivamente, -0,0801 e -0,0761. Códigos de categorias não foram convertidos arbitrariamente em números para Pearson.

Ausências e interpretação

Os efeitos principais usam os observados em cada variável/par; por isso o tamanho avaliado pode mudar. Ausências continuam como grupo explícito nos perfis e cruzamentos, e uma medida com essa categoria adicional permite análise de sensibilidade. Alternativas como "Não respondeu" são preservadas como respostas, não como nulos. Não se apresentam testes de significância, valores-p ou conclusões causais.

3 Relação das 40 entradas com a nota de CN

A Tabela 1 apresenta todas as entradas. Valores maiores de η^2 indicam maior separação entre médias dos grupos observados, sem controlar outras características. O número de categorias e a cobertura diferem: esta ordenação não é uma seleção automática de atributos nem uma classificação de importância causal.

Tabela 1: Varredura completa: relação univariada com CN e cobertura.

Variável	η^2	*n* observado	Ausência (%)
Dependência administrativa	0,1722	579.550	73,09
Renda familiar	0,1430	2.153.941	0,00
Computadores	0,1259	2.153.941	0,00
Ocupação do pai/responsável	0,0941	2.153.941	0,00
Escolaridade do pai/responsável	0,0877	2.153.941	0,00
Ocupação da mãe/responsável	0,0817	2.153.941	0,00
Escolaridade da mãe/responsável	0,0800	2.153.941	0,00
Banheiros	0,0795	2.153.941	0,00
Carros	0,0720	2.153.941	0,00
Aspirador de pó	0,0621	2.153.941	0,00
Televisores	0,0547	2.153.941	0,00
Língua estrangeira	0,0527	2.153.941	0,00
Tipo de escola	0,0506	2.153.941	0,00
Micro-ondas	0,0477	2.153.941	0,00
Máquina de lavar roupa	0,0457	2.153.941	0,00
Cor/raça autodeclarada	0,0443	2.153.941	0,00
Freezer	0,0437	2.153.941	0,00
Celulares	0,0361	2.153.941	0,00
UF de aplicação da prova	0,0346	2.153.941	0,00
Quartos	0,0312	2.153.941	0,00
Empregado doméstico	0,0217	2.153.941	0,00
TV por assinatura	0,0208	2.153.941	0,00
Internet	0,0193	2.153.941	0,00
Telefone fixo	0,0158	2.153.941	0,00
Máquina de lavar louça	0,0151	2.153.941	0,00
Sexo informado	0,0138	2.153.941	0,00
Geladeiras	0,0118	2.153.941	0,00
DVD	0,0118	2.153.941	0,00
Ano de conclusão	0,0117	2.153.941	0,00
Secadora de roupa	0,0107	2.153.941	0,00
Pessoas na residência	0,0101	2.153.941	0,00
Situação do ensino médio	0,0065	2.153.941	0,00
Localização da escola	0,0034	579.550	73,09
Nacionalidade	0,0027	2.153.941	0,00
Faixa etária	0,0022	2.153.941	0,00
Motocicletas	0,0021	2.153.941	0,00
Treineiro	0,0006	2.153.941	0,00
Estado civil	0,0005	2.153.941	0,00
Modalidade de ensino	0,0005	825.858	61,66
Funcionamento da escola	0,0004	579.550	73,09

Fonte: elaboração com os microdados do Inep (2023), somente desenvolvimento.

Leitura: A dependência administrativa tem o maior efeito entre seus observados, mas exclui 1.574.391 ausências desse cálculo específico. Renda e computadores têm cobertura integral. O baixo η^2 de uma variável não elimina a possibilidade de interações ou uso preditivo.

4 Condições socioeconômicas e acesso a recursos

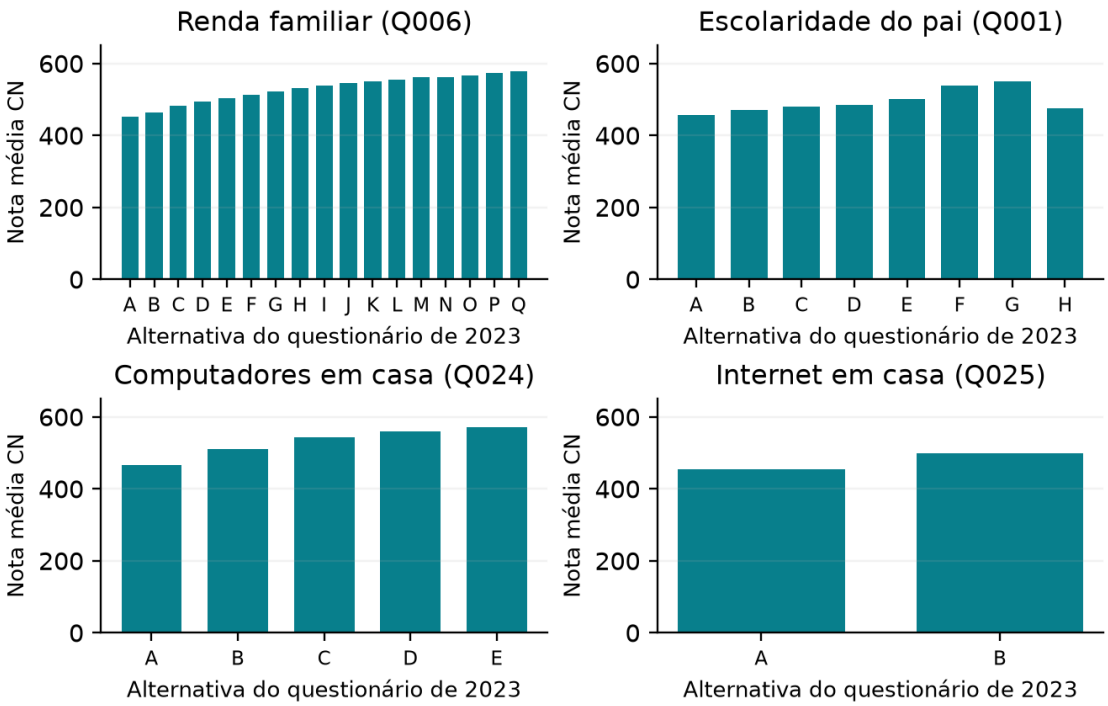


Figura 2: Nota média por renda, escolaridade do pai, computadores e internet.

Fonte: elaboração com os microdados do Inep (2023), somente desenvolvimento.

Renda familiar. A média cresce de 452,98 no grupo A (nenhuma renda, $n = 125.616$) para 577,34 no grupo Q (acima de R$ 26.400,00, $n = 33.930$), diferença bruta de 124,36 pontos. As alternativas são as faixas monetárias do questionário de 2023, e não valores corrigidos para 2026. Renda familiar também não equivale a renda individual ou por pessoa.

Escolaridade dos responsáveis. As categorias de escolaridade apresentam diferenças de média. Em Q001 e Q002, A significa nunca ter estudado; F, faculdade completa; G, pós-graduação; H, desconhecimento da resposta. H não representa um nível acima de G. Os rótulos completos de todas as alternativas estão no dicionário do painel.

Recursos domésticos. Em Q024, a média é 466,94 sem computador e 572,51 com quatro ou mais. Em Q025, as médias são 455,21 sem internet e 499,45 com acesso. Esses resultados descrevem grupos com condições econômicas e escolares distintas; não estimam o efeito de fornecer um equipamento.

Pessoas na residência. Pearson e Spearman para Q005 indicam associação negativa de pequena magnitude. A comparação por quantidades também não é monotônica em toda a escala. Grupos extremos têm poucos participantes; por exemplo, a alternativa 19 contém apenas 20 observações. Na interface, o mínimo de 30 afeta apenas a exibição do gráfico, preservando os grupos nos dados e nas tabelas.

Leitura: As relações de renda, escolaridade e bens se sobrepõem. Seus efeitos univariados não devem ser somados para estimar uma “explicação total” da nota.

5 Contexto escolar, cobertura e cruzamentos

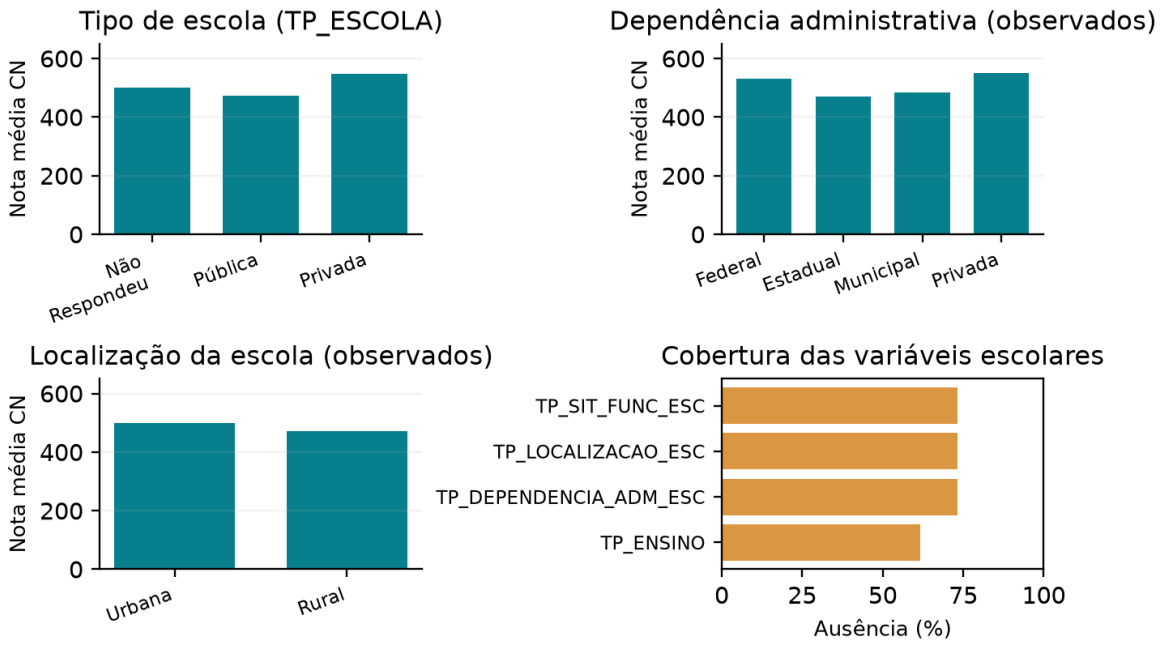


Figura 3: Médias por contexto escolar e ausência nas entradas escolares.

Fonte: elaboração com os microdados do Inep (2023), somente desenvolvimento.

A média de CN é 473,60 na escola pública ($n = 666.620$) e 548,42 na privada ($n = 177.424$), diferença bruta de 74,82 pontos. O grupo "Não respondeu" permanece separado ($n = 1.309.897$, média 499,93). O tipo de escola não representa, isoladamente, a qualidade de uma escola ou rede.

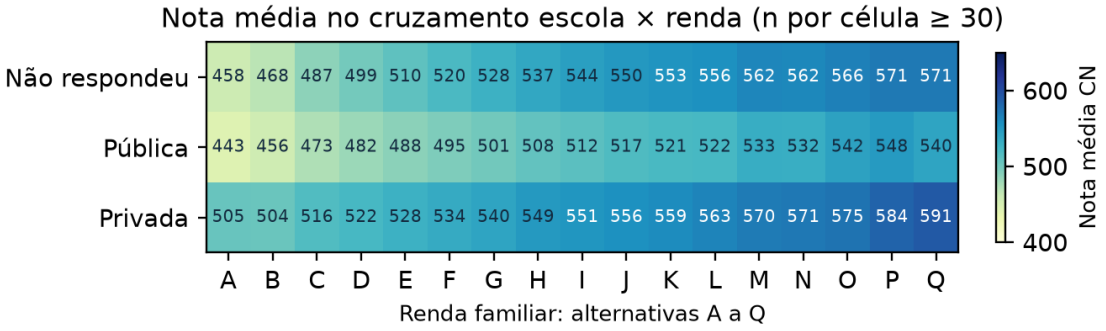


Figura 4: Nota média por tipo de escola e renda familiar.

Fonte: elaboração com os microdados do Inep (2023), somente desenvolvimento.

O cruzamento mostra como comparar perfis dentro de faixas de renda. Nenhuma célula é uma estimativa causal: escolaridade familiar, localização, trajetória e outras condições podem variar dentro dela. O painel oferece as contagens e o desvio de cada célula, inclusive as que não aparecem no mapa por terem menos de 30 participantes.

As três entradas de dependência administrativa, localização e funcionamento têm 73,09% de ausência. Tipo/modalidade de ensino tem 61,66%. As comparações observadas dessas variáveis usam apenas a parte preenchida, que pode ser seletiva. A imputação das entradas nos modelos é uma etapa distinta, aprendida no treino; não foi usada para inventar respostas nesta exploração.

6 Perfil demográfico e distribuição territorial

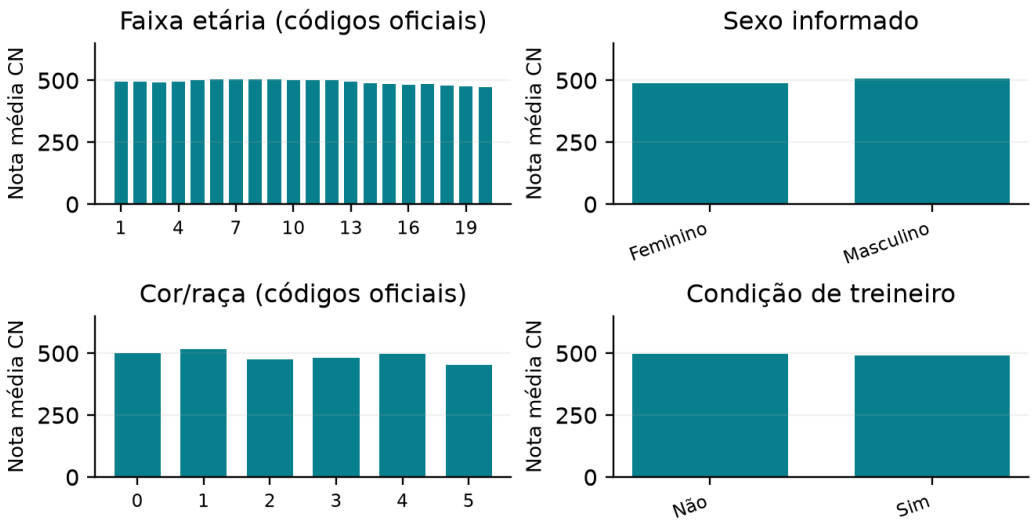


Figura 5: Nota média por faixa etária, sexo, cor/raça e treineiro.

Fonte: elaboração com os microdados do Inep (2023), somente desenvolvimento.

Os grupos demográficos apresentam diferenças descritivas, mas os códigos de faixa etária são intervalos, não idades exatas. Cor/raça é autodeclarada; não se atribui uma explicação biológica a diferenças de notas. Categorias de não informação seguem o dicionário. Treineiros continuam incluídos, conforme o protocolo do estudo.

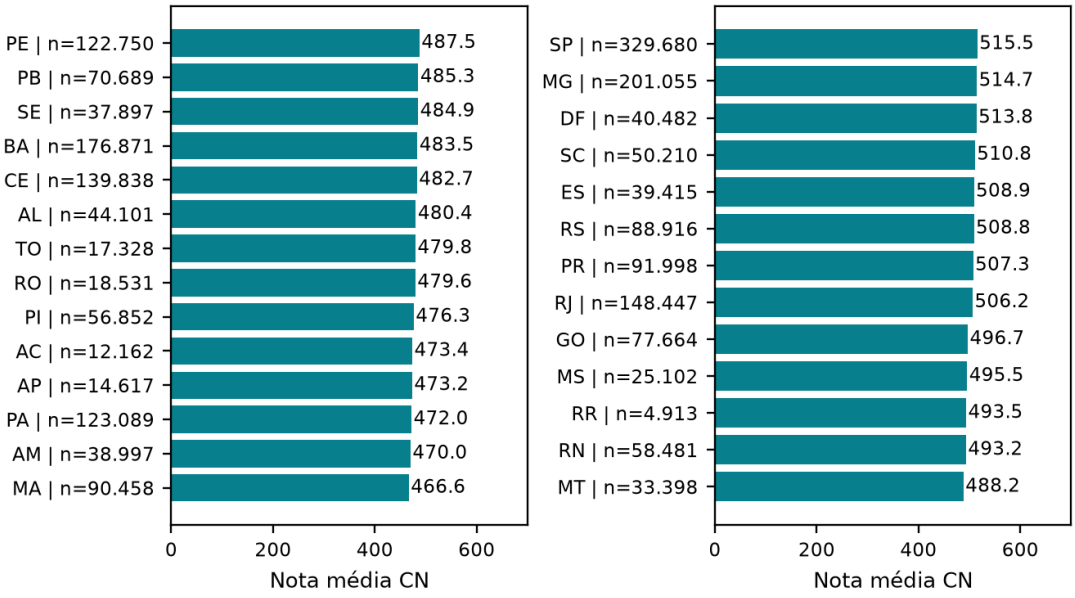


Figura 6: Comparação entre as 27 UFs de aplicação, com tamanhos dos grupos.

Fonte: elaboração com os microdados do Inep (2023), somente desenvolvimento.

Leitura: A UF identifica o local da prova, não necessariamente residência ou escola. Composição de participantes, renda e contexto escolar diferem entre UFs. As médias não constituem um ranking de qualidade educacional nem medem a população inteira de estudantes.

7 Associações entre entradas e possível redundância

Todos os 780 pares estão nos arquivos de resultados e na interface. A figura usa uma seleção legível de 12 categóricas; o usuário pode consultar a matriz das 39 categóricas. Nos 39 pares mistos, a análise da quantidade de moradores usa η^2 em tabela separada.

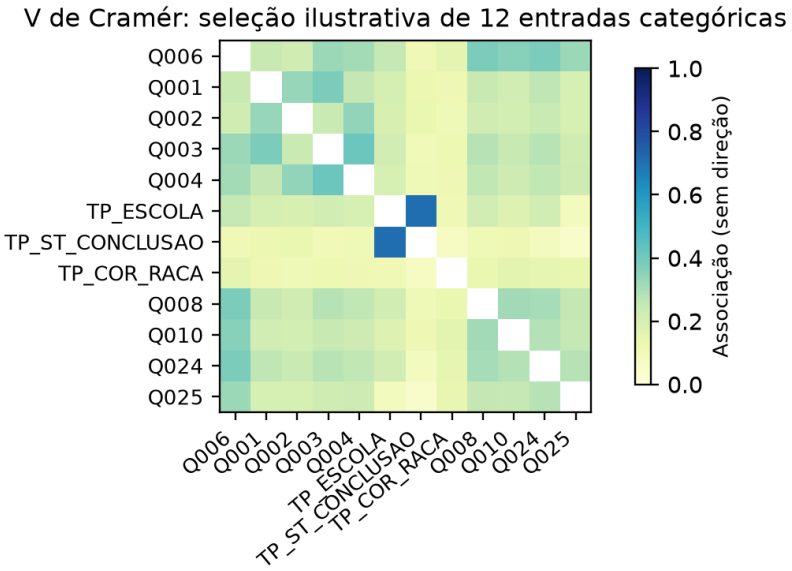


Figura 7: Associações categóricas em um subconjunto ilustrativo; diagonal omitida.

Fonte: elaboração com os microdados do Inep (2023), somente desenvolvimento.

Tabela 2: Sete maiores valores de V de Cramér nos pares observados.

Entrada A	Entrada B	V	n observado
Situação do ensino médio	Treineiro	1,000	2.153.941
Faixa etária	Treineiro	0,755	2.153.941
Situação do ensino médio	Tipo de escola	0,707	2.153.941
Tipo de escola	Dependência administrativa	0,659	579.550
Faixa etária	Situação do ensino médio	0,618	2.153.941
Renda familiar	Aspirador de pó	0,543	2.153.941
Situação do ensino médio	Ano de conclusão	0,535	2.153.941

Fonte: elaboração com os microdados do Inep (2023), somente desenvolvimento.

O V de 1,000 entre conclusão do ensino médio e treineiro expressa uma relação determinística entre categorias observadas neste conjunto; não implica causalidade. Relações entre renda e bens, ou entre escolaridade e ocupação dos responsáveis, indicam informação parcialmente compartilhada. Elas justificam investigar redundância e regularização em novos experimentos, sem excluir automaticamente uma entrada.

Leitura: A tabela também mostra pares com cobertura parcial. O arquivo completo preserva o efeito com ausência como categoria adicional, útil para perceber associações ampliadas por padrões de preenchimento. Não foram usados limiares universais de “forte” ou “fraco”.

8 Modelagem inicial: resultados e leitura correta

Foram realizadas 12 avaliações: quatro modelos nas mesmas três dobras de desenvolvimento. O baseline prevê a média do treino. A regressão linear não usa regularização; Ridge usa $\alpha = 1$; a árvore usa profundidade máxima 12 e mínimo de 100 exemplos por folha. Não houve nova busca de hiperparâmetros nesta análise de relações.

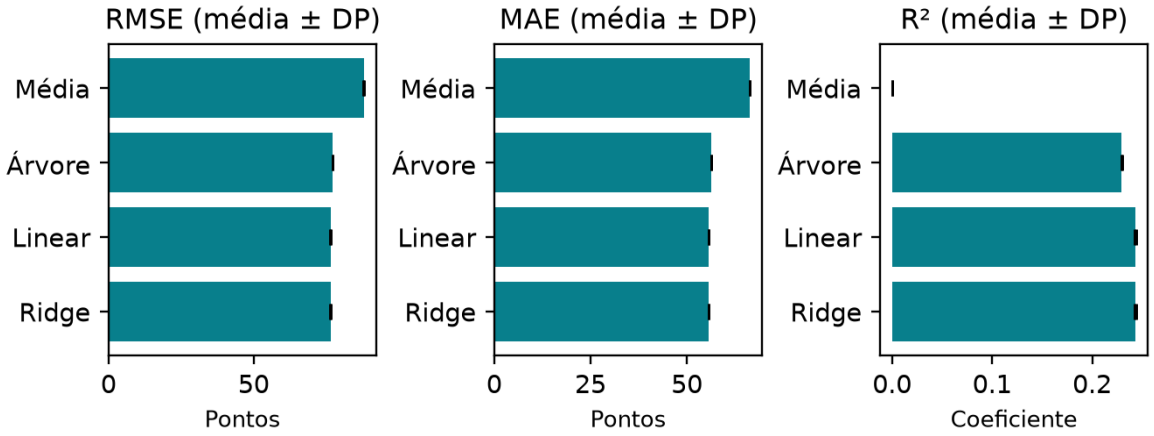


Figura 8: Comparação inicial em validação cruzada, média e desvio entre dobras.

Fonte: elaboração com os microdados do Inep (2023), somente desenvolvimento.

Tabela 3: Métricas iniciais do desenvolvimento; DP com divisor 3.

Modelo	RMSE ± DP	MAE ± DP	R^2 ± DP	Tempo (s)
Ridge	76,48 ± 0,05	55,62 ± 0,04	0,2433 ± 0,0005	89,33
Linear	76,48 ± 0,05	55,62 ± 0,04	0,2432 ± 0,0005	118,26
Árvore	77,17 ± 0,04	56,29 ± 0,02	0,2297 ± 0,0005	556,22
Média	87,92 ± 0,08	66,24 ± 0,04	-0,0000 ± 0,0000	0,09

Fonte: elaboração com os microdados do Inep (2023), somente desenvolvimento.

RMSE é a medida principal; MAE e R^2 complementam sua interpretação [6]. Para $e_i = y_i - \hat{y}_i$:

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_i e_i^2}, \quad \mathrm{MAE} = \frac{1}{n}\sum_i |e_i|, \quad R^2 = 1 - \frac{\sum_i e_i^2}{\sum_i (y_i - \bar{y})^2}.$$

Linear e Ridge reduziram o RMSE em aproximadamente 13,01% frente ao baseline. A diferença entre seus RMSEs médios é menor que 0,001 ponto, inferior à variação entre dobras; não demonstra superioridade prática de Ridge. A árvore teve RMSE maior e consumiu mais tempo nessa configuração. O tempo soma ajuste, previsão e métricas nas três dobras; não inclui carga dos dados nem preparação nacional.

$R^2 \simeq 0,243$ não significa 24,3% de acertos. O resultado indica capacidade preditiva limitada da representação atual, sem avaliar o teste. Os desvios entre dobras não são intervalos de confiança. Ainda não foram produzidos gráficos de resíduos de uma solução final ou curvas que permitam diagnosticar seu ajuste.

9 Implementação, frontend e reprodução

A arquitetura separa preparação, regras do estudo, análise e apresentação. O frontend usa Streamlit 1.66.1 e Plotly 6.9.0, com o mesmo princípio do trabalho anterior: filtros, indicadores, gráficos e tabelas. Os códigos e rótulos oficiais ficam disponíveis ao lado de alternativas legíveis.

Componente	Responsabilidade
`src/enem_base/ingestion.py`	Importação em lotes, qualidade e persistência Parquet.
`src/enem_base/study.py`	Fonte verificada e filtro dos IDs de desenvolvimento.
`src/enem_base/database.py`	Banco SQLite completo, validação e leitura dos agregados.
`src/enem_base/relations.py`	40 entradas, 780 pares, perfis e cruzamentos.
`src/enem_base/dashboard.py`	Snapshot leve para os filtros originais do painel.
`src/enem_base/modeling.py`	Modelos, dobras, métricas e registro de experimentos.
`app/app.py` e `app/app_pages/`	Navegação e cinco páginas da interface.
`src/enem_base/reporting.py`	Figuras e tabelas LaTeX geradas dos agregados.
`tests/` e `scripts/verificar.ps1`	Verificação de contratos, interações e dependências.

Páginas. Visão geral; Explorar dados; Relações e relatório; Modelos; Qualidade e método. Os filtros laterais afetam as duas primeiras. A página de relações apresenta resultados globais, seletores das 40 entradas, qualquer um dos 780 cruzamentos, mapas de associação, CSV, ZIP e este PDF.

Desempenho e rastreabilidade. O snapshot original contém 54.516 grupos em um Parquet de 989.247 bytes. O frontend não lê os milhões de registros a cada interação. São preservados os agregados exatos de contagens e somas; o histograma usa faixas de 25 pontos. Hashes verificam os ativos; fonte ausente ou incompatível interrompe a página, sem substituição por dados fictícios.

Execução local, na raiz do projeto:

```
.\.venv\Scripts\python.exe -m streamlit run app/app.py
.\.venv\Scripts\python.exe scripts/gerar_relatorio.py
```

O endereço é http://127.0.0.1:8501. A narrativa editável está em `relatorio/main.tex`; figuras e tabelas são regeneráveis, sem sobrescrever a narrativa. A compilação LaTeX gera o PDF em `output/pdf/`.

Banco de dados incluído no projeto existente

O arquivo `dados/database/enem2023-v1/enem2023.sqlite3` reúne a base limpa completa e as tabelas abaixo. Preserva texto, códigos, nulos e zeros; Q005 conserva o tipo da preparação e é convertida no tratamento do estudo. A view `desenvolvimento` une participantes e partições e restringe os indivíduos ao desenvolvimento. O frontend usa conexão somente leitura e consulta apenas as tabelas agregadas, sem abrir as notas do teste para análise.

Tabelas do banco	Linhas
`participantes` (76 colunas) / `particoes`	3.933.955 / 2.692.427
`agregados_desenvolvimento`	54.516
`relacoes_alvo` / `associacoes_entradas`	40 / 780
`perfis` / `cruzamentos`	254 / 29.709
`resumo_cv` / `dobras_cv` / `dicionario` / `metadados`	4 / 12 / 76 / 6

Validação. Testes matemáticos confrontam as medidas com cálculos independentes; verificam ausência, constante, simetria e orientação dos pares. Testes AppTest simulam navegação, filtros e exportações [7]. A conferência nacional verifica todos os perfis e cruzamentos contra os tamanhos esperados. O registro técnico atualizado fica em `docs/relacoes_e_relatorio.md`.

10 Conclusões, limites e próximos experimentos

Foi construída uma base técnica reproduzível, com dados nacionais preparados, partições fixas, análise exploratória sistemática, comparação inicial e frontend. As relações sugerem estudar conjuntamente recursos familiares, trajetória escolar e contexto socioeconômico. No estágio atual, os modelos lineares capturam parte da variação da nota e superam a referência pela média, mas permanece erro substancial.

Limites. A análise é observacional; inclui somente candidatos do exame com CN observada no desenvolvimento. Não representa todos os estudantes do país, não controla todos os confundidores e não estima efeitos de intervenções. Respostas são autodeclaradas; ausência escolar é expressiva e pode ser seletiva. Associações univariadas e cruzamentos não esgotam interações de ordem superior. O grande número de comparações não foi usado para alegar significância estatística. O teste permanece reservado, e os resultados não demonstram generalização para outra edição.

Pendência	Próxima evidência necessária
Famílias adicionais de modelos	Comparação nacional nas mesmas três dobras.
Engenharia e seleção; PCA	Três atributos justificados; seleção e PCA em dois regressores.
Balanceamento e buscas	Estratégia só no treino; pelo menos dez configurações em três regressores.
Curva e avaliação final	Congelar a solução; curva em cinco tamanhos e avaliação única do teste.
Entrega acadêmica final	Resíduos e erros por grupo; autores, GitHub, artigo e apresentações.

Este documento explica o trabalho executado até 23/10/2026. Não substitui a entrega final completa prevista no enunciado; resultados ainda não executados não foram inventados.

Referências

[1] INEP. *Microdados do ENEM: edição de 2023 e documentação*. Disponível em: Portal de microdados do ENEM. Acesso em: 23 out. 2026.

[2] SCIPY. *Contingency association: V de Cramér*. Documentação oficial. Acesso em: 23 out. 2026.

[3] SCIPY. *Pearson correlation coefficient (pearsonr)*. Documentação oficial. Acesso em: 23 out. 2026.

[4] SCIPY. *Spearman rank-order correlation (spearmanr)*. Documentação oficial. Acesso em: 23 out. 2026.

[5] SCIKIT-LEARN. *Pipeline*. Documentação oficial. Acesso em: 23 out. 2026.

[6] SCIKIT-LEARN. *Metrics and scoring: regression metrics*. Documentação oficial. Acesso em: 23 out. 2026.

[7] STREAMLIT. *AppTest: testes automatizados de aplicações*. Documentação oficial. Acesso em: 23 out. 2026.